

«А где у вас туалет?»: инстанс-сегментация комнат на поэтажных планах в условиях domain gap между синтетикой и пользовательским контентом

Николай Ридигер¹, Розалия Набиуллина²

¹ Санкт-Петербургский государственный университет телекоммуникаций им. проф. М.А. Бонч-Бруевича

² Донского Государственного Технического университета, города Ростов-на-Дону

Абстракт

Автоматическое распознавание планировки квартиры по изображению плана — практическая, но плохо покрытая задача: открытые датасеты (ResPlan, CubiCasa5K) состоят из чистых, синтетически сгенерированных или отсканированных проектной документацией чертежей, тогда как в реальном сценарии — например, при автоматической обработке объявлений о недвижимости — модель встречает пользовательский контент (UGC): фото плана на объявлении, сделанное под углом, с бликами, низким разрешением или отсканированное с потерями. Мы количественно исследуем размер и природу этого разрыва на задаче сегментации типов комнат, стен и проёмов. Для этого мы (1) обучаем и напрямую сравниваем восемь конфигураций шести архитектур instance- и semantic-сегментации — RF-DETR-Seg, YOLO11-seg, Mask R-CNN, SegFormer, SAM и UNet — по единой методологии оценки; (2) собираем и вручную размечаем instance-сегментацией собственный набор из 33 реальных фотографий планировок с площадки объявлений Avito.Недвижимость, поскольку датасета, отражающего целевой домен, не существовало; (3) проводим независимую проверку части моделей на held-out синтетическом сплите; (4) исследуем пять семейств классических пост-процессинговых методов реконструкции формы комнаты и показываем, что их эффективность строго зависит от того, предсказывает ли модель нативные instance-маски или семантические «блобы»; (5) дополняем основной пайплайн детектором мебели/сантехники на 14 классов и сравнением пяти OCR-конфигураций для извлечения подписанных площадей, формируя трёхступенчатый инференс-пайплайн «сегментация комнат → детекция мебели → OCR».

UGC-датасет с Avito: <https://app.roboflow.com/cultures/toilet-4vbt/browse>

Веса моделей: <https://huggingface.co/nabiullina-dstu/avito-floorplan-checkpoints/tree/main>

Код экспериментов по моделям: https://github.com/rosali3/avito_floorplan_segmentation

Docker-образ: ссылка будет добавлена

Код финального решения: https://github.com/rosali3/avito_prod

Введение

Существующая литература по сегментации поэтажных планов (обзор в §2) в основном опирается на чистые, единообразные по стилю датасеты — векторную графику (ResPlan), синтетические рендеры (RPLAN, MSD) или отсканированную проектную документацию (CubiCasa5K). Реальный сценарий сильно отличается: пользователь фотографирует или сканирует план для объявления, получая изображение с перспективными искажениями, бликами, обрезкой, посторонними объектами в кадре и произвольным качеством печати исходника. Насколько модели, обученные на чистой синтетике, переносятся на такой домен — вопрос, на который в литературе почти нет количественного ответа, поскольку для него не существует открытого бенчмарка.

Мы закрываем этот пробел, выполняя три взаимосвязанные вещи. Во-первых, мы собираем собственный тестовый домен: 33 фотографии реальных планировок с площадки объявлений Avito, вручную размеченные instance-сегментацией по той же таксономии классов, что и обучающие данные, — единственный в этой работе набор, не являющийся синтетикой. Во-вторых, мы обучаем и оцениваем по единой, явно зафиксированной методологии восемь конфигураций шести архитектур сегментации, охватывающих разные парадигмы: transformer-based instance-детекцию (RF-DETR-Seg), одностадийную CNN-детекцию (YOLO-seg), классический двухстадийный детектор (Mask R-CNN), чисто семантическую сегментацию (SegFormer, UNet) и zero-shot foundation-модель (SAM, в связке с Grounding-DINO). В-третьих, мы не ограничиваемся единственным числом mAP: проводим threshold-калибровку, ablation по постобработке маски и независимую проверку на held-out синтетическом сплите, — что в совокупности вскрывает эффекты, невидимые по одной сводной таблице.

Вклад работы

Количественная оценка domain gap между синтетическими планами и реальными UGC-фотографиями на задаче сегментации комнат, впервые измеренная на собственноручно размеченном датасете реального домена. Прямое сравнение восьми обученных конфигураций шести архитектур instance- и semantic-сегментации по единой методологии.

Threshold-sweep, показывающий, что оптимальный рабочий порог специфичен для модели и что выбор единого порога ради честности сравнения имеет измеримую цену в F1 для отдельных архитектур.

Независимая held-out проверка на синтетическом домене, вскрывающая скрытый коллапс модели в мажоритарный класс — эффект, не видимый по метрикам на целевом домене и обнаруживаемый только благодаря дополнительному контрольному сплиту.

Систематическое сравнение пяти семейств пост-процессинга формы маски на всех восьми моделях, показывающее, что выигрыш от классической CV-реконструкции контура ограничен моделями с семантической (не instance) природой предсказания.

Дополнительные компоненты — детектор мебели/сантехники на 14 классов как задел под мебель-осведомлённую коррекцию типа комнаты, и сравнение пяти OCR-конфигураций для извлечения подписанных площадей, — собранные в единый трёхступенчатый инференс-пайплайн.

2. Связанные работы и датасеты

Задача сегментации поэтажных планов опирается на несколько семейств источников данных и методов. ResPlan и CubiCasa5K — крупные датасеты векторных/растровых планов с семантической разметкой типов помещений, широко используемые для предобучения; RPLAN и Modified Swiss Dwellings (MSD) — датасеты планировок многоквартирных зданий с похожей структурой разметки. Ни один из них не содержит фотографий реальных объявлений — их общая черта — чистота источника (векторная графика или контролируемое сканирование), что делает их удобными для обучения, но не для оценки устойчивости к шуму.

Методологически задача решается либо как семантическая сегментация (U-Net, DeepLabV3+, SegFormer — классификация каждого пикселя без разделения на отдельные объекты одного класса), либо как instance-сегментация (Mask R-CNN как классический двухстадийный подход; современные end-to-end детекторы вроде YOLO-seg и transformer-based RF-DETR-Seg). Отдельное направление — адаптация универсальных foundation-моделей сегментации, в первую очередь

Segment Anything Model (SAM), обычно в связке с открыто-словарным детектором (GroundingDINO) для получения промпт-боксов без ручной разметки («Grounded-SAM»); её применимость к специфичному домену чертежей заранее не очевидна и явно проверяется в этой работе.

3. Данные

3.1 Обучающая синтетика

В качестве обучающего домена используется объединение ResPlan v2 и CubiCasa5K: семантические (не instance) маски 256×256, 20 079 изображений, 7 содержательных классов плюс фон и метка ignore. Для архитектур, требующих instance-разметки (RF-DETR, YOLO, Mask R-CNN), семантические маски конвертированы в COCO-формат через выделение связанных компонент (8-connectivity) с последующей полигонизацией. У этого способа есть известное ограничение: пиксели-разделители (например, текстовая подпись площади поверх комнаты) иногда разрезают один визуальный объект на несколько инстансов; поскольку все instance-модели используют один и тот же сконвертированный набор аннотаций, ограничение действует на них идентично и не создаёт систематического преимущества ни одной из них. Train/valid разбиты 80/20 с единым фиксированным seed для всех моделей.

3.2 Целевой домен: датасет UGC-фотографий Avito

Поскольку ни один из существующих датасетов не отражает целевой сценарий — пользовательскую фотографию или скан плана из объявления — мы собрали и разметили собственный набор данных. Изображения планировок отбирались вручную с площадки объявлений о продаже недвижимости Avito и размечены instance-сегментацией по той же 7-классовой таксономии, что и обучающие данные (инструмент разметки — Roboflow).

Перед тем как переходить к ручной разметке, мы отдельно проверили, можно ли получить разметку типов комнат на UGC-фото дешевле — zero-shot, без привлечения человека. Были опробованы три zero-shot источника псевдо-разметки: Claude Sonnet 5 и Qwen 4.5 (промптинг vision-language моделей напрямую на классификацию/локализацию комнат по изображению плана) и SAM (в связке с GroundingDINO, тот же zero-shot пайплайн, что и в основном сравнении моделей, §6). Ни один из трёх вариантов не дал разметки достаточного качества, чтобы использовать её как псевдо-GT без дальнейшей проверки человеком — по итогам этой пробы было принято решение размечать датасет полностью вручную. Количественная оценка качества этих zero-shot псевдо-разметок в текущей версии работы не

приводится и является кандидатом для отдельного расширения (см. также открытый вопрос про VLM zero-shot в мотивации проекта).

Критерии отбора для финальной ручной разметки формулировались так, чтобы датасет тестировал именно устойчивость к дефектам передачи изображения, а не к произвольной графической нотации:

- Исключены рукописные (от руки нарисованные) планы — их условная графика слишком нестандартна, чтобы быть репрезентативной выборкой «план как документ»;
- Исключены маркетинговые рендеры планировок новостроек — они по построению не содержат дефектов пользовательской съёмки и не относятся к UGC в строгом смысле;
- Включены два целевых класса контента: (а) некачественный скан или фотография печатного плана (перспективные искажения, блики, обрезка, низкое разрешение) и (б) полу- или профессионально начерченный план (в т.ч. поэтажный план из технического паспорта или подготовленный агентством), сфотографированный или отсканированный пользователем.

Итоговый набор — 33 изображения; исходная разбивка Roboflow-экспорта на train/valid/test объединена в единый тестовый сплит, полностью исключённый из обучения и подбора гиперпараметров каких-либо моделей. Отдельно отмечаем открытый методологический вопрос: для полу-/ профессионально начерченных планов было бы уместно сослаться на нормативный источник условных графических обозначений (стены, проёмы, размерные линии); вероятные кандидаты — ГОСТ Р 21.1101 (СПДС) или ГОСТ 21.501 — требуют сверки перед фиксацией конкретной ссылки.

Учитывая объём в 33 изображения, все сравнения моделей на этом датасете следует читать как наблюдаемую тенденцию, а не статистически строгое превосходство — в первую очередь это касается редких классов (balcony почти во всех прогонах не имеет ни одного истинного инстанса в тесте). Визуально подтверждено, что train- и test-домены относятся к одному классу изображений (вид сверху с размерами, а не фотография интерьера) — расхождение доменов ограничено качеством передачи изображения, а не типом содержимого.

3.3 Таксономия и маппинг классов

Итоговая таксономия — 7 классов: living, bedroom, bathroom, kitchen, balcony, wall, opening. Категории исходной UGC-разметки сведены к ней следующим образом: restroom → bathroom; door/window/entrance → opening

(по аналогии с тем, что обучающие данные сами объединяют двери и окна в один класс). Категории corridor/hall/room/stairs/storage/toilet (корневой) не имеют прямого аналога и не приравнивались насильно к существующим классам — вместо этого исключаются из GT перед подсчётом метрик, за отдельным исключением категории room (см. §4.1).

4. Методология оценки

4.1 Категория «room» и ignore-регионы

Исходная UGC-разметка не различает living/bedroom — только общую категорию room. Простое отбрасывание таких аннотаций из GT приводило бы к тому, что верное предсказание living или bedroom в этой зоне засчитывалось бы как ложноположительное. Вместо этого геометрия таких аннотаций сохраняется как ignore-регион: предсказания с перекрытием bbox $\geq 50\%$ с ignore-регионом исключаются из подсчёта precision/recall/mAP до оценки, а для самой категории room предсказание засчитывается верным, если модель предсказала в этом месте living ИЛИ bedroom — так реальная ошибка (например, living, предсказанный поверх настоящей ванной) не маскируется под «верное совпадение». Формально в разметке 7 категорий, но фактически участвующих в оценке классов — девять (7 + фон + бакет room).

4.2 Единый confidence-порог и mask-NMS

Порог отсекающий по уверенности предсказаний унифицирован на 0.1 для всех моделей, чтобы сравнение между архитектурами было честным. На этом пороге плохо откалиброванные модели (в первую очередь базовый RF-DETR) выдают множество почти полностью перекрывающихся масок одного объекта; для устранения этого эффекта применяется кросс-классовый Mask-NMS (IoU>0.5, из группы перекрывающихся масок оставляется маска с максимальным score).

4.3 Набор метрик

Используются два взаимодополняющих семейства метрик: стандартный COCO mAP@50/mAP@50:95 (не зависит от рабочего порога, интегрирует всю precision-recall кривую) и pixel-level метрики на фиксированном пороге после NMS — IoU, Dice (математически идентичный F1 для бинарной маски), Precision, Recall, сводный F1. Ассурасу сознательно не приводится: при доминировании фона она стабильно даёт 0.95–0.98 у всех моделей независимо от реального качества и неинформативна для сравнения.

5. Экспериментальная установка

Шесть базовых архитектур (в восьми конфигурациях: RF-DETR-Seg и YOLO-Seg — в базовой версии и версии

с расширенной аугментацией обучающих данных) обучались на выделенной GPU NVIDIA V100 32 ГБ. Дополнительные компоненты — детектор мебели/сантехники (§7.5) и OCR (§7.6) — обучались и тестировались локально, как менее ресурсоёмкие по сравнению с основными архитектурами сегментации.

Обучение каждой модели контролировалось по валидационному сплиту синтетических данных и останавливалось по достижении плато метрики на валидации, то есть по факту сходимости. Собственный UGC-датасет (§3.2) не участвовал ни в обучении, ни в подборе гиперпараметров или чекпоинта ни для одной модели — он используется исключительно как финальный held-out тест.

Модель	Особенность
RF-DETR-Seg (Medium)	Transformer-детектор с сегментационной головой, batch=2, grad_accum=2, lr=1e-4
RF-DETR-Seg fullaug	Та же архитектура, train/valid — данные с дополнительной аугментацией
YOLO11m-seg	batch=8, imgsz=640
YOLO-seg fullaug	Та же архитектура на аугментированных данных
Mask R-CNN (ResNet-50 FPN)	Двухстадийный бейзлайн, дообучение с COCO-претрейна, batch=2, lr=0.0025
SegFormer-b2	Семантическая (не instance) сегментация; instances получены постфактум через connected-components
SAM zero-shot	Grounded-SAM: боксы от GroundingDINO (box_threshold=0.30, text_threshold=0.25), маски от SAM без дообучения
SAM fine-tuned	Дообучен только mask_decoder (encoder/prompt-encoder заморожены), боксы по-прежнему от GroundingDINO
UNet-simple (референс)	Обучена вне этого исследования, бейзлайн «простая семантика без всего остального»

6. Результаты на UGC-тесте

6.1 Сводная таблица (агрегат по классам, порог 0.1, с mask-NMS)

Модель	IoU	Dice/F1	Precision	Recall	mAP@50	mAP@50:95
YOLO-seg	0.300	0.524	0.803	0.348	0.279	0.184
RF-DETR fullaug	0.254	0.463	0.759	0.305	0.200	0.123
YOLO fullaug	0.233	0.424	0.802	0.267	0.240	0.154
UNet-simple	0.212	0.396	0.280	0.482	0.053	0.023

Модель	IoU	Dice/F1	Precision	Recall	mAP@50	mAP@50:95
Mask R-CNN	0.209	0.387	0.597	0.290	0.218	0.142
RF-DETR-Seg	0.213	0.385	0.247	0.616	0.329	0.216
SegFormer	0.192	0.360	0.348	0.454	0.085	0.035
SAM zero-shot	0.022	0.082	0.040	0.099	0.002	0.002
SAM fine-tuned	0.011	0.042	0.022	0.037	0.001	0.000

Ранжирование по метрике зависит от того, какой аспект качества она измеряет: по сводному F1 на фиксированном рабочем пороге лидирует YOLO-seg; по mAP, не зависящему от единого порога и интегрирующему всю precision-recall кривую, — RF-DETR-Seg. Расхождение объясняется калибровкой: у RF-DETR 3104 из 3387 сырых предсказаний имеют score < 0.3 (против 56 из 366 у YOLO), поэтому её объективно неплохое ранжирование предсказаний не реализуется в F1 на едином пороге 0.1.

6.2 По классам (F1)

Модель	bathroom	kitchen	wall opening	room	
RF-DETR-Seg	0.16	0.21	0.46	0.42	0.67
RF-DETR fullaug	0.31	0.48	0.54	0.45	0.54
YOLO-seg	0.64	0.38	0.58	0.48	0.55
YOLO fullaug	0.55	0.15	0.53	0.49	0.41
Mask R-CNN	0.38	0.32	0.17	0.42	0.64
SegFormer	0.16	0.26	0.56	0.31	0.51
UNet-simple	0.26	0.30	0.51	0.34	0.57
SAM zero-shot	—	—	—	0.06	0.17
SAM fine-tuned	—	—	—	0.08	0.05

6.3 Обсуждение

Domain gap. Разрыв между качеством на синтетической валидации (mIoU/mAP порядка 0.6–0.9) и на UGC-тесте (AP 0.02–0.33) устойчиво наблюдается у всех девяти конфигураций — это не артефакт конкретной архитектуры, а системный эффект перехода от чистых чертежей к зашумлённым фотографиям.

Instance vs semantic. Модели с нативной instance-головой (RF-DETR, YOLO, Mask R-CNN) устойчиво точнее по mAP, но модели с чисто семантической сегментацией (SegFormer, UNet) выше по recall (0.45–0.48 против 0.29–0.38) — они находят больше площади нужного класса ценой заметно худшей точности границ и формы.


Foundation-модель не переносится без адаптации. Zero-shot Grounded-SAM практически не работает на этом домене: GroundingDINO не приспособлен искать комнаты на схематичных чертежах (детальный разбор — §8). Аугментация данных — не гарантированная win-win стратегия. Расширенная аугментация обучающих данных (fullaug) на UGC-тесте хуже базовых версий RF-DETR и YOLO, несмотря на явный прирост качества на собственной синтетической валидации — контраст, дополнительно подтверждённый в §7.3.

7. Дополнительные эксперименты

7.1 Эффект mask-NMS

Модель	До NMS	После NMS	Удалено
RF-DETR (base)	3387	1687	50.2%
RF-DETR fullaug	315	293	7.0%

Половина сырых предсказаний базового RF-DETR на пороге 0.1 — дубли одного и того же объекта; их удаление поднимает macro F1 с 0.305 до 0.385 (+0.080). У fullaug-версии эффект минимален — модель заметно лучше откалибрована и меньше дублирует детекции.



7.2 Threshold sweep

порог	YOLO F1(macro)	RF-DETR F1(macro)	RF-DETR room F1
0.10	0.524	0.385	0.675
0.15	0.524	0.455	0.746
0.20	0.524	0.468	0.672

YOLO-seg уже оптимален на пороге 0.1 (плато 0.05–0.25), тогда как RF-DETR теряет до 0.083 macro F1 из-за единого порога — это измеримая цена, сознательно заплаченная за честность межмодельного сравнения, а не случайный недосмотр.

7.3 Проверка на held-out синтетическом сплите

Отдельно прогнаны RF-DETR (base, fullaug) и UNet на held-out изображениях того же домена, что обучение — с нативной 7-классовой разметкой, без необходимости в ignore-регионах.

Находка: базовый RF-DETR коллапсирует в мажоритарный класс. На низком пороге per-class mIoU ≈ 0.016 , при этом class-agnostic IoU (объект/не объект, без учёта конкретного класса) = 0.53 — модель находит объекты примерно там же, где GT, но почти всегда присваивает им один и тот же класс на всю картинку. Наиболее вероятное объяснение — недообученность на момент используемого чекпоинта: пространственная локализация уже освоена, различие типов комнат — ещё нет. Этот режим отказа не виден по агрегированным метрикам на UGC (табл. 6.1), где RF-DETR формально занимает верхнюю строчку по mAP, — он проявляется только при отдельной проверке per-class качества на независимом сплите.

Модель	mIoU (per-class)	class-agnostic IoU
RF-DETR (base)	0.016	0.534
UNet (сырой)	0.787	0.876
RF-DETR fullaug	0.815	0.884

Контрольный пересчёт на честном пересечении train/valid-сплитов (гарантированно held-out для обеих версий RF-DETR) подтвердил превосходство fullaug (mIoU 0.806 против 0.016 у base) — это не артефакт утечки данных. Показательно, что на UGC (§6.3) соотношение обратное: аугментация помогает на родном синтетическом домене, но не гарантированно переносится на реальные дефекты целевого домена — этот контраст был бы незаметен без параллельной оценки на двух разных тестовых доменах.

7.4 Пост-процессинг формы маски

Мы систематически оценили пять семейств классических методов восстановления формы комнаты — заливку областей, ограниченных предсказанной моделью стеной; squareness-фильтр по aspect ratio (cv2.minAreaRect); реконструкцию границ по Canny-эджам исходного фото (опционально с обрезкой по границам чертежа через Otsu-порог); CLAHE и adaptive threshold как альтернативные предобработки — на всех восьми конфигурациях моделей.

Модель	Лучший метод	Δ room F1
SegFormer	Canny + extent-crop (Otsu)	+0.026
UNet	Canny-fill	+0.020

Модель	Лучший метод	Δ room F1
YOLO fullaug	canny_fill	+0.022
SAM (zero-shot / fine-tuned)	canny_extent_crop	+0.042 / +0.046 (от низкой базы)
Mask R-CNN	squareness (a=3.0)	+0.002
RF-DETR / RF-DETR fullaug / YOLO	squareness	≈ 0.000

Воспроизводимый выигрыш наблюдается только у моделей, изначально дающих «блобы» без чёткой формы (SegFormer, UNet, в относительных цифрах — SAM); для моделей с нативной instance-маской (RF-DETR, YOLO, Mask R-CNN) пост-процессинг не даёт систематического выигрыша — реконструкция контура им не нужна.

7.5 Детектор мебели и сантехники

В качестве задела под мебель-осведомлённую коррекцию типа комнаты (интуиция: наличие унитаза — сильный сигнал в пользу санузла, наличие дивана исключает ванную) обучен независимый детектор YOLO11n-seg на 14 классах мебели и сантехники (toilet, sink, bathtub, sauna_bench, fireplace, chimney, closet, appliance, sofa, bed, chair, table, cabinet, shower) на объединении трёх источников: SFPI (готовая COCO-разметка), FloorPlanCAD (11 мебельных классов из 30, структурные элементы отброшены) и CubiCasa5K (SVG-парсинг мебельных элементов с калиброванным аффинным преобразованием SVG→растр через ECC по реальным стенам плана — наивное масштабирование в первой итерации давало несовпадение координат). Итоговый датасет — 7900 train + 1736 val изображений (CubiCasa5K составляет лишь ~11% train). Обучение и все прогоны этого компонента выполнены локально.

На собственном held-out (SFPI/FloorPlanCAD) детектор достигает mAP50(mask)=0.992 и визуально работает уверенно (confidence 0.84–0.99, корректно различает до 42 объектов на плотных планах). На UGC-тесте модель визуально сломана: почти на каждом изображении она заливает весь план классом sink с высоким score, включая подписи площади, номера комнат и водяной знак площадки объявлений. Количественно на UGC модель не оценивалась (нет GT для мебели), но визуальный паттерн идентичен коллапсу RF-DETR (§7.3): модель, обученная исключительно на чистой синтетике, не переносится на шумные реальные фото. Добавление CubiCasa5K в обучение резко просадило mAP на собственной валидации (0.99→0.52), но при малом числе

эпох с нуля — причина (домен CubiCasa5K или недообученность) не установлена однозначно и требует контрольного прогона.

7.6 OCR подписанных площадей

Для задачи извлечения текстовых подписей площади комнат сравнены пять конфигураций OCR по recall относительно ручной разметки (75 строк, 67 валидных чисел). Все прогоны выполнены локально:

Метод	Recall
EasyOCR baseline	13.4%
EasyOCR + CLAHE + upscale	20.9%
Tesseract digits-only	19.4%
PaddleOCR + CLAHE	14.9%
PaddleOCR без предобработки	38.8%

PaddleOCR без предобработки — безоговорочный лидер, почти вдвое лучше следующего результата. Показательно, что одна и та же предобработка (CLAHE, апскейл) помогает EasyOCR и вредит PaddleOCR — единого рецепта предобработки «для OCR вообще» не существует, подбор нужен отдельно под конкретный движок.

8. Пайплайн инференса

Итоговый сквозной инференс собран как последовательность трёх независимых этапов: (1) сегментация комнат — основная модель сравнения (по результатам §6, базовый кандидат — YOLO-seg как лидер по F1 на рабочем пороге, либо RF-DETR-Seg при приоритете на mAP/recall) размечает границы и типы комнат, стен и проёмов; (2) детекция мебели и сантехники (§7.5) запускается на том же изображении независимо от первого этапа; (3) OCR подписанных площадей (§7.6, PaddleOCR без предобработки) извлекает текстовые подписи для последующего сопоставления с масками комнат. Этапы не образуют строгую зависимость (второй и третий не используют выход первого как обрезку) — это осознанное упрощение текущей версии; сигнал мебели для явной коррекции предсказанного типа комнаты (мотивация в §7.5) в ранкер пока не встроен и остаётся направлением дальнейшей работы.

9. Отрицательный результат: дообучение SAM decoder'a не улучшает качество

Decoder SAM дообучался отдельно (image encoder и prompt encoder заморожены) на 20 эпохах, val_loss монотонно снизился с 0.0587 до 0.0393 — обучение сошло штатно. Тем не менее AP@50:95 на UGC соста-

вил 0.0002 против 0.0016 у zero-shot версии — практически без изменений. Причина в том, что промпт-боксы для SAM по-прежнему подаются от GroundingDINO, а он, как показано в §6.3, почти не находит комнаты на этом домене. Каким бы качественным ни было дообучение decoder'a, если промпт-бокс не попадает в объект, итоговая маска будет неверной. Это иллюстрирует общий принцип для связок вида detector+SAM: узкое место — именно детекция промпт-боксов, а не сегментация внутри уже заданного бокса, и улучшение только одного компонента связки не решает проблему целиком.

10. Future work

Заметка для следующей редакции: в текущей версии fullaug-конфигурации RF-DETR и YOLO (§5–7) упоминаются только по факту использования расширенной аугментации, но сама методология аугментаций (какие именно преобразования, с какими параметрами, на каком коде) не описана отдельным разделом, и нет ablation по отдельным видам аугментаций (какая из них вносит основной вклад в разницу с base). Это нужно добавить: (1) отдельный подраздел «Аугментации» с описанием пайплайна; (2) эксперименты, изолирующие вклад отдельных аугментаций друг от друга, а не только сравнение «есть/нет fullaug» одним числом.

11. Ограничения

Тестовая выборка — 33 собственноручно размеченных изображения; mAP и разбивка по классам на ней статистически ненадёжны, особенно для balcony (в GT почти всегда 0 инстансов).

Единый confidence-порог 0.1, необходимый для честности межмодельного сравнения, не является F1-оптимальным индивидуально как минимум для RF-DETR (§7.2).

Детектор мебели и OCR количественно не оценены на UGC-домене — нет соответствующей ручной разметки. Held-out-проверка UNet на синтетике не является гарантированно честным hold-out'ом: модель обучена вне рамок этого исследования, на собственном train/valid-сплите.

Нормативная ссылка для критерия «полу-/профессионально начерченный план» в отборе UGC-данных (§3.2) требует уточнения — кандидатные стандарты (ГОСТ Р 21.1101, ГОСТ 21.501) пока не сверены.

12. Заключение

Мы показали, что разрыв между качеством сегментации комнат на синтетических поэтажных планах и на реальных фотографиях объявлений устойчив, велик по абсо-

лютной величине и системно воспроизводится вне зависимости от архитектуры — включая современные transformer-based детекторы и zero-shot foundation-модели. Ключевым инструментом для этого измерения стал собственноручно собранный и размеченный набор из 33 реальных планировок с Avito, отобранных по явным критериям, отделяющим дефекты передачи изображения от произвольной графической нотации: без такого датасета разрыв можно было бы оценить только качественно. Дополнительные эксперименты — threshold-калибровка, независимая проверка на held-out синтетическом сплите, систематическое сравнение пост-процессинга — показали, что единственная сводная метрика способна скрывать существенные эффекты (плохую калибровку уверенности, коллапс модели в мажоритарный класс, чувствительность выигрыша от постобработки к природе предсказания модели), заметные только при более детальном анализе. Расширение основного пайплайна детектором мебели и OCR-модулем демонстрирует, что тот же эффект domain gap — обучение на чистой синтетике при отсутствии переноса на шумный целевой домен — воспроизводится и за пределами задачи сегментации комнат как таковой, что говорит о его общей природе для этого класса задач, а не о специфике конкретной архитектуры или конкретного класса.